

杨惠瑶



AI Agent / 大模型应用开发工程师

北京 | 3 年经验 | 本科 | 一个月内到岗

13103035256 | 1548824224@qq.com

核心优势

- 2 年企业级大模型应用开发经验，主导 2 个 AI Agent 项目从需求分析、架构设计、研发测试到私有化部署及客户验收，具备从 0 到 1 生产落地经验。
- 专注 Agent 工程化，具备 Multi-Agent、Agent Loop、Tool Calling、MCP、RAG、Context Engineering、长任务执行、异常恢复与全链路 Trace 实践；建设 30+ Native Tools 与 72+ Skills 动态加载体系。
- 具备 RAG 全链路优化能力，能够针对不同业务场景定位检索不准、知识召回不足及模型回答偏差等问题，并通过评测与 Bad Case 分析持续迭代，提升知识检索准确性与最终回答质量。
- 具备大模型评测、推理部署与私有化交付经验，能够基于业务场景完成模型选型、效果验证与环境适配，曾完成 8 × 海光 K100_AI 64 GB DCU 环境下的 vLLM 适配、故障定位及客户交付。

专业技能

Agent / LLM 应用：Multi-Agent Runtime、Agent Loop、Task Planning、Native Function Calling、Tool Calling Framework、MCP、Dynamic Skills、Memory Management、Context Engineering、Tool Self-Healing

RAG / 知识工程：Document Parsing、Domain-aware Chunking、BGE-M3、FAISS + BM25 Hybrid Retrieval、Cross-Encoder Rerank、RAG Evaluation、Incremental Indexing、Metadata Filtering、Structured Knowledge Extraction

模型与推理：LiteLLM、OpenAI-Compatible API、vLLM、Qwen / DeepSeek、Embedding / Reranker 本地推理、模型评测与选型、Token / Context Window 管理、Retry / Fallback

后端与工程化：Python、FastAPI、Django、asyncio、RabbitMQ、Redis、PostgreSQL、Docker、Linux、异步任务、Task Lifecycle、Agent Tracing、私有化部署

工作经历

中科数测科技有限公司 | 大模型应用开发 / 核心研发

2024.07 - 至今

负责产品：多功能漏洞挖掘智能体、自动化模糊测试智能体

- Agent 核心研发：负责企业级 AI Agent 架构与工程研发，落地任务规划、Multi-Agent 协作、Tool Calling、RAG、上下文管理、长任务执行及异常恢复等核心能力。
- 安全场景融合：面向源码审计、Web 渗透、协议模糊测试与固件分析，将大模型推理、知识检索与安全工具链融合为自动化任务闭环。
- 模型与应用优化：围绕 Prompt、上下文裁剪、知识检索、模型适配及效果评测持续迭代，提升复杂长链路任务的稳定性、准确性与执行效率。
- 方案验证与落地：通过 PoC、真实任务评测与场景适配验证新模型、Agent 范式及开源框架，将具备业务价值的能力集成到现有产品。

- 端到端交付：覆盖需求分析、技术方案、研发测试、前后端联调、模型服务适配、离线环境部署、复杂问题排查与客户验收。

项目经历

安星 / 自动化漏洞挖掘 Multi-Agent 平台

项目描述：面向源码审计、Web 安全测试及自动化漏洞分析场景，负责 LLM Agent Engine 核心能力建设，通过自研 Multi-Agent Runtime、Tool Calling、动态 Skill、Context Engineering 与 Docker Sandbox，实现任务规划、工具执行、漏洞验证及报告生成的自动化闭环。

技术栈：Python、LiteLLM、Pydantic、FastAPI、Multi-Agent、Native Tool Calling、RabbitMQ、Docker、asyncio、OpenAI-Compatible API

核心工作：

- 负责自研 Multi-Agent Runtime 核心模块设计，构建 Root Agent / Sub Agent 层级任务模型，通过 Agent Graph 管理父子关系、运行状态及消息通信，实现复杂任务拆解、子任务委派与结果汇总。
- 负责 Tool Calling Framework 建设，基于 Tool Registry + Schema Validation 实现工具动态注册、参数校验及 Function Calling 转换，接入 Agent 协作、Shell / Python、文件、网络分析及漏洞报告等 30+ Native Tools。
- 针对 Tool 参数错误与长链路调用失败设计自动恢复机制，将 Schema、错误原因及参数约束重新注入模型上下文，引导 LLM 自动修正 Tool Call，并结合超时、重试及异常处理提升连续工具调用稳定性。
- 负责 Agent 长上下文与 Memory Compression 模块，根据 Context Window / Token 使用量动态触发多级压缩，对 Tool Result、Error、Retry 及历史推理差异化保留，并通过本地 Extractive Fallback 保证摘要异常时任务持续执行。
- 负责动态 Skill 能力体系设计，按源码审计、Web、渗透测试等运行场景配置 Skill / Tool 白名单，支持 Agent 按任务动态加载 70+ 场景化 Skills，减少无关 Prompt 注入并控制子 Agent 能力边界。
- 负责模型接入与执行隔离能力建设，基于 LiteLLM 封装统一 LLM Gateway，兼容 OpenAI-Compatible 模型及 Function Calling；通过 Docker Sandbox + FastAPI Tool Server 隔离模型推理与 Shell / Python 等高风险工具执行。
- 负责 Agent 服务化与可观测性建设，基于 RabbitMQ 实现任务消费、Heartbeat、取消、失败恢复及结果回传，并对 Agent Thinking、Tool Call、Finding、Progress 等事件建立结构化 Trace，支撑任务回放、问题定位及报告交付。

面向通信协议安全分析的领域 RAG 知识增强平台

项目描述：面向 RFC 标准协议及私有通信协议，负责领域 RAG 系统建设，将协议规范转换为可检索、可溯源的知识，并通过 MCP 为大模型 Agent 提供协议理解、状态分析及测试用例生成能力。

技术栈：Python、FastAPI、LangChain、FAISS、BGE-M3、BGE-Reranker、BM25、SQLite、PyMuPDF、MCP

核心工作：

- 负责领域 RAG Pipeline 建设，完成 PDF / Word / HTML / XML / JSON 等文档解析、清洗、切片、Embedding、检索及重排，并保留 Source / Page / Chunk Metadata 实现结果溯源。
- 针对协议文档优化 Chunking 策略，按 RFC Section、MUST / SHOULD / MAY、ABNF 及私有协议消息 / 字段表进行结构化切分，避免固定长度切片破坏协议语义。
- 负责 Hybrid Retrieval + Rerank 链路，基于 BGE-M3 + FAISS 进行语义召回，结合 BM25 补充字段名、状态码等精确术语检索，并通过 Cross-Encoder 完成二阶段精排。

- 负责 RAG 离线评测与 Bad Case 分析，围绕协议字段、状态码、消息格式及 RFC 规则构建 Ground Truth 测试集，使用 Recall@K、MRR / NDCG 评估 Dense / Hybrid / Rerank 链路，并基于漏召、错排及跨协议误召持续优化 Chunk 策略、TopK、融合权重与相关性过滤规则。
- 负责 Embedding / Rerank 推理层封装，兼容本地模型与 OpenAI-Compatible API，支持模型懒加载、Batch Encoding、CPU / CUDA 自动切换及多 Reranker Backend，适配不同离线部署环境。
- 负责知识库索引及增量更新机制，采用 FAISS + SQLite DocStore 管理向量、原文及 Metadata，通过文件指纹识别新增 / 修改 / 删除文档，实现增量 Embedding 与 Source 级索引更新。
- 针对私有协议实现结构化知识抽取，解析消息类型、Frame / Sub Type、字段长度、请求响应及状态关系，生成 Protocol Manifest，将非结构化 RAG 与确定性协议知识结合，降低模型对协议结构的猜测。
- 负责 RAG 与 Agent 集成，将知识库构建、协议检索、消息及状态查询封装为 MCP Tools，并增加相关性过滤、上下文裁剪及索引缺失降级，减少无关知识导致的模型幻觉。
- 负责知识库服务化与业务接入，基于 FastAPI 提供文档上传、异步建库、状态查询及文件管理接口，并将协议知识接入 Agent 测试工作流，支撑协议建模与测试用例生成。

教育背景

保定理工学院 | 物联网工程 | 本科

2020.07 - 2024.07